Universidade Federal do Rio Grande do Norte
Instituto Metrópole Digital
IMD0601 - Bioestatística

Organização dos dados em R

Prof. Dr. Tetsu Sakamoto
Instituto Metrópole Digital - UFRN
Sala A224, ramal 182
Email: tetsu@imd.ufrn.br

Baixe a aula (e os arquivos)

- Para aqueles que não clonaram o repositório:

```
> git clone https://github.com/tetsufmbio/IMD0601.git
```

- Para aqueles que já tem o repositório local:

```
> cd /path/to/IMD0601
```

```
> git pull
```

Procedimentos da análise de dados

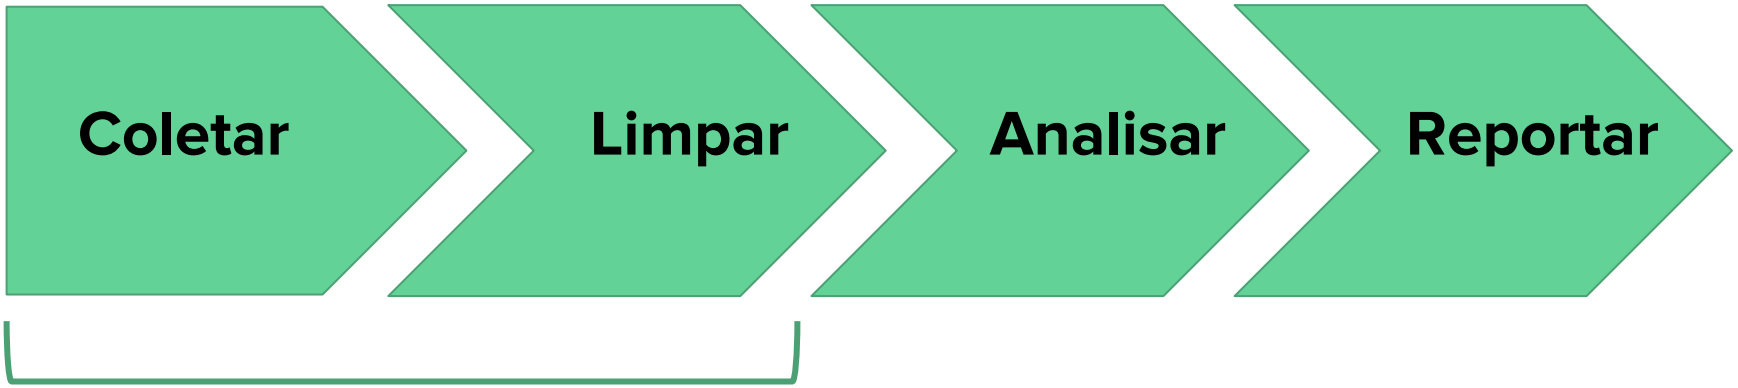

Limpando os dados

- Explorar os dados
  - Entender a sua estrutura;
  - Verificar a qualidade dos dados;
- Tidying data (arrumando os dados)
  - Facilitar a manipulação e a análise dos dados;

Explorando os dados

`dim(v)`	Mostra as dimensões de uma tabela v (linha x coluna);
`nrow(v)`	Mostra o número de linhas em v;
`ncol(v)`	Mostra o número de colunas em v;
`names(v)`	Mostra os nomes das colunas;
`object.size(v)`	Mostra o espaço ocupado na memória por v;
`head(v)`	Mostra as 6 primeiras linhas de v;
`tail(v)`	Mostra as 6 últimas linhas de v;
`summary(v)`	Mostra um breve sumário de v;
`table(v)`	Conta o número de ocorrência de cada categoria em v;
`str(v)`	Mostra a estrutura de v;

Explorando os dados

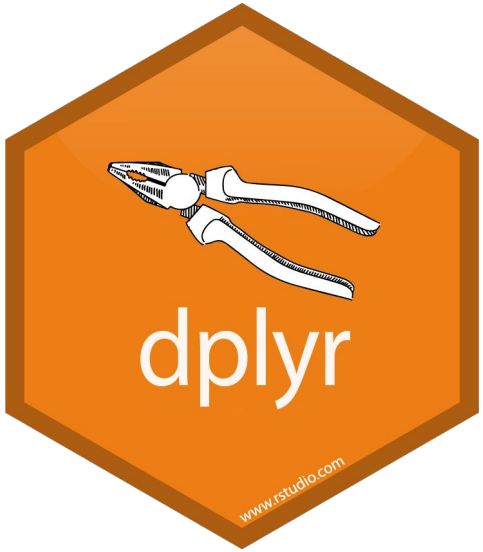

Pacote dplyr

- https://dplyr.tidyverse.org/
- Escrito por Hadley Wickham e Romain Francois;
- Oferece funções consistentes e concisas para manipular dados tabulares.

Pacote dplyr

- select() ➜ seleciona as variáveis (colunas) desejadas;
  - `select(<tbl_df>, <var1>, <var2>, ...)`
  - `select(cran, ip_id, package, country)`
- filter() ➜ filtra as linhas de acordo com as condições especificadas;
  - `filter(<tbl_df>, <condition1>, <condition2>, ...)`
  - `filter(cran, r_version == "3.1.1", country == "US")`
- arrange() ➜ ordena as linhas na ordem crescente ou decrescente;
  - `arrange(<tbl_df>, <var1>, desc(<var2>),...)`
  - `arrange(cran2, country, desc(r_version), ip_id)plyr`
- mutate() ➜ adiciona colunas;
  - `mutate(<tbl_df>, <new_var1> = <value>, <new_var2> = <value>,...)`
  - `mutate(cran3, size_mb = size / 2^20, size_gb = size_mb / 2^10)`
- summarize() ➜ reduz múltiplos valores a um sumário;
  - `summarize(<tbl_df>, <column> = <function>)`
  - `summarize(cran, avg_bytes = mean(size))`

Tidying data

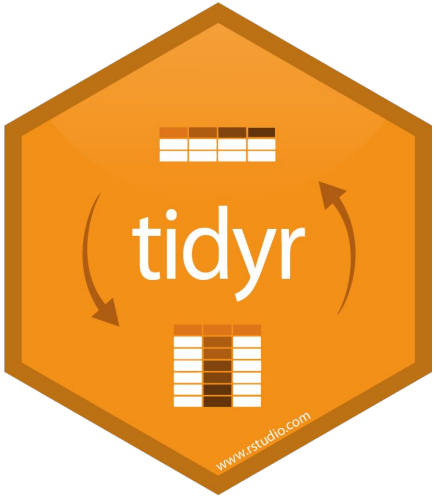

Pacote tidyr

- Hadley Wickham
- Paper: “Tidy data” (http://vita.had.co.nz/papers/tidy-data.pdf)
- Tidy data são dados formatados de forma padronizada que facilita a exploração e a análise dos dados. Um tidy data satisfaz as seguintes condições:
  - Cada variável deve estar em uma coluna;
  - Cada observação forma uma linha;
  - Cada tipo de unidade observacional forma uma tabela.

Messy data 1

```
> students
  grade male female
1     A    1      5
2     B    5      0
3     C    5      2
4     D    5      5
5     E    7      4
```

Problema: Colunas **male** e **female** representam valores de uma variável

```
gather(<tbl>, <key>, <value>, <columns>)
```

```
> gather(students, sex, count, -grade)
   grade    sex count
1      A   male     1
2      B   male     5
3      C   male     5
4      D   male     5
5      E   male     7
6      A female     5
7      B female     0
8      C female     2
9      D female     5
10     E female     4
```

Messy data 2

```
> students2
  grade male_1 female_1 male_2 female_2
1     A      3        4      3        4
2     B      6        4      3        5
3     C      7        4      3        8
4     D      4        0      8        1
5     E      1        1      2        7
```

Problema: Múltiplas variáveis armazenadas em uma coluna (sexo e classe)

Messy data 2

```
> res <- gather(students2, sex_class, count, -grade)
> res
   grade sex_class count
1      A    male_1     3
2      B    male_1     6
3      C    male_1     7
4      D    male_1     4
5      E    male_1     1
6      A  female_1     4
7      B  female_1     4
8      C  female_1     4
...
```

Problema: Duas variáveis distintas em uma coluna (sex_class)

Messy data 2

```
> separate(data = res, col = sex_class, into = c("sex", "class"))
   grade    sex class count
1      A   male     1     3
2      B   male     1     6
3      C   male     1     7
4      D   male     1     4
5      E   male     1     1
6      A female     1     4
7      B female     1     4
8      C female     1     4
9      D female     1     0
...
```

Messy data 3

Problema: Variáveis armazenadas tanto nas colunas quanto nas linhas.

```
> students3
    name    test class1 class2 class3 class4 class5
1  Sally midterm      A   <NA>      B   <NA>   <NA>
2  Sally   final      C   <NA>      C   <NA>   <NA>
3   Jeff midterm   <NA>      D   <NA>      A   <NA>
4   Jeff   final   <NA>      E   <NA>      C   <NA>
5  Roger midterm   <NA>      C   <NA>   <NA>      B
6  Roger   final   <NA>      A   <NA>   <NA>      A
7  Karen midterm   <NA>   <NA>      C      A   <NA>
8  Karen   final   <NA>   <NA>      C      A   <NA>
9  Brian midterm      B   <NA>   <NA>   <NA>      A
10 Brian   final      B   <NA>   <NA>   <NA>      C
```

Deveriam ser valores da variável class

Cada um deveria ser uma variável tendo como valor a nota

Messy data 3

```
> res <- gather(students3, class, grade, class1:class5, na.rm=TRUE)
> res
    name    test  class grade
1  Sally midterm class1     A
2  Sally   final class1     C
9  Brian midterm class1     B
10 Brian   final class1     B
13  Jeff midterm class2     D
14  Jeff   final class2     E
15 Roger midterm class2     C
16 Roger   final class2     A
...
```

Juntando as colunas class1 a class5 de forma que eles se tornem valores da coluna **class**, e seus valores da tabela antiga fiquem na coluna **grade**.

Messy data 3

```
> res <- spread(res, test, grade)
> res
    name  class final midterm
1  Brian class1     B       B
2  Brian class5     C       A
3   Jeff class2     E       D
4   Jeff class4     C       A
5  Karen class3     C       C
6  Karen class4     A       A
7  Roger class2     A       C
8  Roger class5     A       B
...
```

Pega os valores distintos da coluna **test** e transforma cada uma em uma coluna (**final**, **midterm**). Seus valores são preenchidos pelos valores da coluna **grade**.

Messy data 3

```
> library(readr)
> mutate(res, class = parse_number(class))
    name class final midterm
1  Brian     1     B       B
2  Brian     5     C       A
3   Jeff     2     E       D
4   Jeff     4     C       A
5  Karen     3     C       C
6  Karen     4     A       A
7  Roger     2     A       C
8  Roger     5     A       B
...
```

parse_number() retira qualquer caracteres não numéricos que esteja antes ou depois do primeiro número. Uso do **mutate()** para transformar os valores da coluna **class** em apenas número.

Messy data 4

```
> students4
    id  name sex class midterm final
1  168 Brian   F     1       B     B
2  168 Brian   F     5       A     C
3  588 Sally   M     1       A     C
4  588 Sally   M     3       B     C
5  710  Jeff   M     2       D     E
6  710  Jeff   M     4       A     C
7  731 Roger   F     2       C     A
8  731 Roger   F     5       B     A
9  908 Karen   M     3       C     C
10 908 Karen   M     4       A     A
```

Problema: Múltiplas unidades observacionais em uma única tabela. Dados redundantes na tabela.

Messy data 4

```
> student_info <- select(students4, id, name, sex)
> student_info
    id  name sex
1  168 Brian   F
2  168 Brian   F
3  588 Sally   M
4  588 Sally   M
5  710  Jeff   M
6  710  Jeff   M
7  731 Roger   F
8  731 Roger   F
...
```

Selecionando as colunas **id**, **name** e **sex** da tabela students4.

Messy data 4

```
> unique(student_info)
   id  name sex
1 168 Brian   F
3 588 Sally   M
5 710  Jeff   M
7 731 Roger   F
9 908 Karen   M
```

Usando a função **unique()** para retirar as linhas duplicadas.

Messy data 4

```
> gradebook <- select(students4, id, class, midterm, final)
> gradebook
    id class midterm final
1  168     1       B     B
2  168     5       A     C
3  588     1       A     C
4  588     3       B     C
5  710     2       D     E
6  710     4       A     C
7  731     2       C     A
8  731     5       B     A
...
```

Retirar as colunas incorporadas na outra tabela usando o **select()**, mas mantendo a coluna **id**, pois ele funcionaria como uma chave primária em um banco de dados relacional.

Messy data 5

```
> passed
   name class final
1 Brian     1     B
2 Roger     2     A
3 Roger     5     A
4 Karen     4     A
```

```
> failed
   name class final
1 Brian     5     C
2 Sally     1     C
3 Sally     3     C
4  Jeff     2     E
5  Jeff     4     C
6 Karen     3     C
```

Problema: Uma unidade observacional em duas tabelas separadas.

Messy data 5

```
> passed <- mutate(passed,
status = "passed")
> passed
   name class final status
1 Brian     1     B passed
2 Roger     2     A passed
3 Roger     5     A passed
4 Karen     4     A passed
```

```
> failed <- mutate(failed,
status = "failed")
> failed
   name class final status
1 Brian     5     C failed
2 Sally     1     C failed
3 Sally     3     C failed
4  Jeff     2     E failed
5  Jeff     4     C failed
6 Karen     3     C failed
```

Usando o **mutate()** para adicionar uma coluna **status**.

Messy data 5

```
> bind_rows(passed, failed)
    name class final status
1  Brian     1     B passed
2  Roger     2     A passed
3  Roger     5     A passed
4  Karen     4     A passed
5  Brian     5     C failed
6  Sally     1     C failed
7  Sally     3     C failed
8   Jeff     2     E failed
9   Jeff     4     C failed
10 Karen     3     C failed
```

Usando a função **bind_rows()** para juntar duas tabelas.

Exercício

Veja os dados dentro da variável **sat**. Tente realizar as seguintes tarefas:

1. Selecione todas as colunas que não contenha “total” (veja a função contains());
2. Junte todas as colunas, exceto a coluna score_range. Utilize key = part_sex e value = count;
3. Separe a coluna part_sex em duas variáveis chamados de “part” e “sex”.
4. Use a função group_by() para agrupar as amostras pela coluna “part” e “sex” nesta ordem.
5. Utilize mutate() para adicionar duas novas colunas cujo os valores serão:
    a. total = sum(count)
    b. prop = count / total

Referência

Esta aula foi baseada no curso **Getting and Cleaning Data** do grupo **Swirl**.

Mais informações em: https://swirlstats.com/scn/getclean.html