Universidade Federal do Rio Grande do Norte Instituto Metrópole Digital IMD0601 - Bioestatística

Visualização dos dados em R

Prof. Dr. Tetsu Sakamoto Instituto Metrópole Digital - UFRN Sala A224, ramal 182 Email: tetsu@imd.ufrn.br








Baixe a aula (e os arquivos)


- Para aqueles que não clonaram o repositório:
- > git clone https://github.com/tetsufmbio/IMD0601.git
- Para aqueles que já tem o repositório local:
- > cd /path/to/IMD0601
- > git pull

Cientistas de dados;


Combina as áreas de:

- Estatística: análise gráfica dos dados (Representação e interpretação dos dados);
- Design: Princípios de design (gráficos atrativos e que promove o melhor entendimento e comunicação);







https://r4ds.had.co.nz/introduction.html









Anscombe, FJ. Graphs in Statistical Analysis. American Statistician, 1973.









Anscombe, FJ. Graphs in Statistical Analysis. American Statistician, 1973.








Anscombe, FJ. Graphs in Statistical Analysis. American Statistician, 1973.








Anscombe, FJ. Graphs in Statistical Analysis. American Statistician, 1973.

Propriedade	Valor	Precisão
Média de x	9	exato
Variância de x	11	exato
Média de y	7,50	até 2 casas decimais
Variância de y	4,125	±0,003
Correlação entre x e y	0,816	até 3 casas decimais
Reta de regressão linear	y = 3,00 + 0,500x	até 2 e 3 casas decimais, respectivamente
Coeficiente de determinação da regressão linear: \mathbb{R}^2	0,67	até 2 casas decimais





Anscombe, FJ. Graphs in Statistical Analysis. American Statistician, 1973.

Gráficos exploratórios

- Gerado facilmente;
- Dados pesados;
- Para uma audiência específica (você e seus colegas);
- Análise gráfica dos dados;
- Servem para analisar e confirmar.

R Base Graphics


Gráficos explanatórios

- Laboriosos;
- Específicos para determinados dados;
- Para uma audiência ampla (publicação ou apresentação);
- o Parte comunicativa do processo.
- Servem para informar e persuadir.

Ggplot2, ggvis lattice

R Base Graphics

R Base Graphics: An Idiot's Guide



Task Views Search

About R R Homepage The R Journal

Software R Sources R Binaries 12 Graphical procedures

12.1 High-level plotting commands

12.1.1 The plot() function

12.1.2 Displaying multivariate data

12.1.3 Display graphics

12.1.4 Arguments to high-level plotting functions

12.2 Low-level plotting commands

12.2.1 Mathematical annotation

12.2.2 Hershey vector fonts

12.3 Interacting with graphics

12.4 Using graphics parameters

12.4.1 Permanent changes: The par() function

12.4.2 Temporary changes: Arguments to graphics functions

12.5 Graphics parameters list

12.5.1 Graphical elements

12.5.2 Axes and tick marks

12.5.3 Figure margins

12.5.4 Multiple figure environment

PROGRAMMING, R, UDACITY

SWIRL - R PROGRAMMING - I FSSON 15 - BASE GRAPHICS

HOW-TO & USEFUL STUFF


Base Graphics in R: A Detailed Idiot's Guide


R Base Graphics


```
plot(x = cars$speed, y = cars$dist,
xlab = "Speed", ylab = "Stopping
Distance", col = 2)

boxplot(formula = mpg~cyl, data =
mtcars)

hist(mtcars$mpg)
```







Overview


ggplot2 part of the tidyverse

ggplot2 is a system for declaratively creating graphics, based on The Grammar of Graphics. You provide the data, tell ggplot2 how to map variables to aesthetics, what graphical primitives to use, and it takes care of the details.

Installation

The easiest way to
install.packages("ti

Alternatively, ins
install.packages("gg
Or the development
install.packages('
devtools::install_gi



Links

Download from CRAN at https://cloud.r-project.org/

package=ggplot2

Browse source code at

https://github.com/tidyverse/ggplot2/

Report a bug at

https://github.com/tidyverse/ggplot2/

issues

Learn more at

https://r4ds.had.co.nz/data-

visualisation.html

Extensions at


https://exts.ggplot2.tidyverse.org/gallery/

Hadley Wickham

"The Grammar of Graphics"

Adiciona camadas nos gráficos para melhor visualização dos dados;

library(ggplot2)



Data

Dados (tabela) onde se encontram as variáveis a serem representados graficamente.

ggplot(data=mtcars)

ggplot(mtcars)



Aesthetics

Permite especificar as variáveis que queremos utilizar na representação gráfica.


ggplot(mtcars, aes(x=mpg, y=wt))



Geometries


Camada que indica a forma como os dados devem ser apresentados no gráfico.

```
ggplot(mtcars, aes(x=mpg,
y=wt)) + geom_point()
```




Facets

Permite colocar múltiplos gráficos em um canvas.




Statistics

Adiciona uma camada que representa uma análise estatística.



Coordinates


Camada que controla como as posições devem ser mapeadas no gráfico (limites do eixo x e y).



Themes

Camada que permite enriquecer a apresentação **Statistics** do gráfico (rótulos, fonte, cor, etc).

Install.packages('ggThemeAssist')




Iris dataset

```
data(iris)
                                             Iris Versicolor
                                                               Iris Virginica
                                                       Iris Setosa
str(iris)
'data.frame': 150 obs. of 5 variables:
 $ Sepal.Length: num 5.1 4.9 4.7 4.6 5 5.4 4.6 5 4.4 4.9 ...
 $ Sepal.Width : num 3.5 3 3.2 3.1 3.6 3.9 3.4 3.4 2.9 3.1 ...
 $ Petal.Length: num  1.4 1.4 1.3 1.5 1.4 1.7 1.4 1.5 1.4 1.5 ...
 $ Petal.Width : num   0.2   0.2   0.2   0.2   0.4   0.3   0.2   0.1   ...
 $ Species
           : Factor w/ 3 levels "setosa", "versicolor", ...: 1 1
 1 1 1 1 1 1 1 . . .
```

Base plot

Sepal length X Sepal width




> plot(iris\$Sepal.Length, iris\$Sepal.Width)

Base plot

Como adicionar os dados de Petal length e Petal width?

- > plot(iris\$Sepal.Length, iris\$Sepal.Width)
- > points(iris\$Petal.Length, iris\$Petal.Width, col = "red")




Limitações:

- O gráfico não é redesenhado;
- O gráfico gerado é uma imagem;
- A legenda é adicionada manualmente;
- Não há uma framework unificado para gerar diferentes tipos de gráficos.

Sepal length X Sepal width


> ggplot(iris, aes(x = Sepal.Length, y = Sepal.Width))

+ geom_point()



Como adicionar os dados de Petal length e Petal width?

```
> ggplot(iris, aes(x = Sepal.Length, y = Sepal.Width)) +
    geom_point() +
    geom_point(aes(x = Petal.Length, y = Petal.Width),
col = "red")
```



Exercício

Adicione uma coluna na tabela **iris** que corresponda a um identificador único de cada observação.

```
> iris$Flower <- 1:nrow(iris)</pre>
```


Crie uma tabela onde as variáveis Length e Width estejam cada uma em uma coluna, como abaixo.

```
Species Flower part Length Width
1 setosa 1 Petal 1.4 0.2
2 setosa 1 Sepal 5.1 3.5
```

Exercício

```
> library(tidyr)
> iris$Flower <- 1:nrow(iris)</pre>
> iris.wide <- gather(iris, part measure, val, -Species, -Flower )</pre>
> iris.wide <- separate(iris.wide, part measure,</pre>
c("part", "measure"))
> iris.wide <- spread(iris.wide, measure, val)</pre>
```

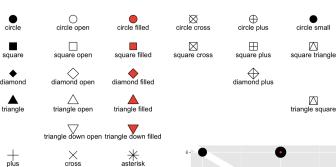
ggplot(iris.wide, aes(Length, Width, col = part)) + geom_point()




Parâmetros típicos da estética

- $\mathbf{x} \rightarrow \text{posição no eixo x}$;
- y → posição no eixo y;
- col → cor dos pontos ou formas;
- fill \rightarrow cor a ser preenchida;
- size → diâmetro do ponto, largura da linha;
- alpha → transparência;
- linetype → padrão de tracejamento;
- labels → texto no gráfico;
- $shape \rightarrow formas;$









ggplot(iris.wide, aes(Length, Width, col = part, shape = Species))

+ geom_point()



ggplot(iris.wide, aes(Length, Width, col = Species, shape = part))

+ geom_point()



A sintaxe do ggplot

```
ggplot(data = <DATA>) +
                                                   Data
                                                                        {variables of interest}
  <GEOM_FUNCTION>(
                                                                     colour
                                                                                size
                                                                                         alpha
                                                                                                  line width
                                                           x-axis
                                            Aesthetics
                                                           y-axis
                                                                      fill
                                                                               labels
                                                                                         shape
                                                                                                  line type
      mapping = aes(<MAPPINGS>),
                                           Geometries
                                                            point
                                                                             histogram
                                                                      line
                                                                                          bar
                                                                                                  boxplot
      stat = <STAT>,
                                               Themes non-data ink
      position = <POSITION>
                                              Statistics
                                                           binning
                                                                   smoothing descriptive inferential
                                           Coordinates
                                                          cartesian
                                                                      fixed
                                                                               polar
                                                                                         limits
                                                Facets
                                                          columns
  <COORDINATE FUNCTION> +
                                                                      rows
  <FACET_FUNCTION>
```

Referências

- Aula baseada no curso "**Data Visualization with ggplot2 (Part 1)**" de Rick Scavetta: https://www.datacamp.com/courses/data-visualization-with-ggplot2-1
- Ciência de Dados com R IBPAD: https://www.ibpad.com.br/o-que-fazemos/publicacoes/introducao-ciencia-de-dados-com-r/
- Tidyverse: https://ggplot2.tidyverse.org/index.html (link para cheat sheet!)
- R for data Science: https://r4ds.had.co.nz/
- https://skillgaze.com/2017/10/31/understanding-different-visualization-layers-of-ggplot/