

Universidade Federal do Rio Grande do Norte
Instituto Metr pole Digital
IMD0601 - Bioestat stica

Infer ncia Bayesiana

Prof. Dr. Tetsu Sakamoto
Instituto Metr pole Digital - UFRN
Sala A224, ramal 182
Email: tetsu@imd.ufrn.br



Baixe a aula (e os arquivos)

- Para aqueles que não clonaram o repositório:

```
> git clone https://github.com/tetsufmbio/IMD0601.git
```

- Para aqueles que já tem o repositório local:

```
> cd /path/to/IMD0601
```

```
> git pull
```

Revisão

Distribuição multivariada

- **Multinomial**
- **Normal**
- **Dirichlet**

Inferência Bayesiana

Diferença essencial

- **Frequentista X Bayesiana** → Forma de interpretar a probabilidade

Jogada de moeda justa → $P(\text{cara}) = \frac{1}{2}$;

- **Frequentista**
 - Experimento repetido várias vezes → proporção de cara aproxima de $\frac{1}{2}$;
 - Probabilidade é a média aritmética dos resultados do experimento.
 - Uma verdade, e uma medida fixa;

Diferença essencial

- **Frequentista X Bayesiana** → Forma de interpretar a probabilidade

Jogada de moeda justa → $P(\text{cara}) = \frac{1}{2}$;

- **Bayesiana**
 - Não interpreta a probabilidade como um valor fixo ou verdadeiro;
 - Probabilidade como uma medida de grau pessoal de crença em relação a uma hipótese;
 - Não existe uma medida verdadeira, mas sim uma certa distribuição de probabilidade associada às suas crenças subjetivas;
 - A probabilidade de um resultado de uma jogada de uma moeda é uma variável aleatória que possui uma distribuição de probabilidade associada.

Diferença essencial

- **Frequentista X Bayesiana** → Forma de interpretar a probabilidade

Jogada de moeda justa → $P(\text{cara}) = 1/2$;

- **Bayesiana**
 - Utilizando o conhecimento subjetivo, tenta primeiro estipular qual a probabilidade de um parâmetro → **distribuição a priori** → **distribuição beta**;
 - Coleta de dados e baseado nos dados coletados o modelo é atualizado → **distribuição a posteriori**;
 - Como escolher os parâmetros a priori? Como os dados são modelados? Como os modelos são atualizados?

Diferença essencial

- **Frequentista X Bayesiana** → Forma de interpretar a probabilidade

Jogada de moeda justa → $P(\text{cara}) = 1/2$;

- **Bayesiana**
 - Pode escolher a prior que $P(\text{cara}) = 1/10$, e não $1/2$ (Experiência com moedas não justas);
 - Um estatístico bayesiano pode não apresentar as mesmas probabilidades a priori;
 - Bayesiana utiliza as crenças subjetivas para produzir um modelo inicial de distribuição de probabilidade;
 - A incorporação de uma crença subjetiva é o que diferencia a bayesiana dos frequentistas.

Por que aprender inferência bayesiana?

- **Menos teórico** → baseado em apenas um paradigma → Teorema de Bayes;
- **Bom aproveitamento do poder computacional** → pacotes em R que utilizam a abordagem bayesiana para realizar tarefas computacionalmente intensivas;
- **Flexibilidade** → Extremamente flexível em modelar distribuições de dados e pode ser aplicada em diversas situações;
- **Dados faltantes** → cobre efetivamente os dados faltantes;
- **Múltiplas variáveis**;
- **É um método de aprendizagem** → atualização constante do modelo;
- **Não requer número de amostras grandes** → Algoritmos como MCMC pode ser realizado para produzir resultados significativos mesmo com pequenas amostras.

Desvantagens sobre a inferência bayesiana

- **Críticas sobre a subjetividade do método** → pode ser visto como não científico e enviesado. É a principal fonte de disputa entre os frequentistas e bayesianos;
- **Pouco entendido** → Modelos bayesianos não são largamente ensinados e utilizados;
- **Complicado?** → Quando apresentado matematicamente, a abordagem aparenta ser complicado;

Teorema de Bayes

Uma simples regra dentro da probabilidade.

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

$$P(B|A) = \frac{P(B \cap A)}{P(A)}$$

$$P(A|B) \cdot P(B) = P(A \cap B)$$

$$P(B|A) \cdot P(A) = P(B \cap A)$$

$$P(A \cap B) = P(B \cap A)$$

$$P(A|B) \cdot P(B) = P(B|A) \cdot P(A)$$

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$$

**Teorema de
Bayes**

Teorema de Bayes

Variações do teorema de Bayes

$$P(A|B) = \frac{P(B|A).P(A)}{P(B)}$$

$$P(A|B) \propto P(B|A).P(A) \quad P(B) \text{ constante, } \propto = \text{“proporcional a”}$$

$$P(H|E) = \frac{P(E|H).P(H)}{P(E)}$$

E = Evidência

H = Hipótese

P(H) = probabilidade a priori antes da evidência

P(H|E) = probabilidade a posteriori depois da evidência

P(E|H) = probabilidade da evidência dada hipótese

Aplicando o teorema de Bayes

Tabela abaixo mostra a probabilidade conjunta de dois eventos: “A” onde a proteína se liga na membrana e “B” onde a proteína possui alta proporção de resíduos hidrofóbicos.

		Tipo de proteína	
		Liga na membrana (A)	Não liga na membrana (A ^c)
Proporção de resíduos hidrofóbicos	Alta (B)	0,3	0,2
	Baixa (B ^c)	0,1	0,4

Qual a probabilidade de uma proteína ter alta proporção de resíduos hidrofóbicos dado que ela é uma proteína de membrana?

Aplicando o teorema de Bayes

Qual a probabilidade de uma proteína ter alta proporção de resíduos hidrofóbicos dado que ela é uma proteína de membrana?

		Tipo de proteína	
		Liga na membrana (A)	Não liga na membrana (A ^c)
Proporção de resíduos hidrofóbicos	Alta (B)	0,3	0,2
	Baixa (B ^c)	0,1	0,4

$$P(B|A) = \frac{P(A|B).P(B)}{P(A)} = \frac{P(A \cap B)}{P(A)}$$

Aplicando o teorema de Bayes

		Tipo de proteína		marginal
		Liga na membrana (A)	Não liga na membrana (A ^c)	
Proporção de resíduos hidrofóbicos	Alta (B)	0,3	0,2	0,5
	Baixa (B ^c)	0,1	0,4	0,5
	marginal	0,4	0,6	

$$P(B|A) = \frac{P(A \cap B)}{P(A)} = \frac{0,3}{0,4} = 0,75$$

Aplicando o teorema de Bayes

Suponha que ter um gene X resulta na manifestação de uma doença em 50% dos casos. Suponha que a prevalência deste gene em uma população é de $1/1000$ e que a prevalência da doença é de 1%. Sabendo disso, calcule a probabilidade de ter o gene X dado que você tem a doença.

Aplicando o teorema de Bayes

Suponha que ter um gene X resulta na manifestação de uma doença em 50% dos casos. Suponha que a prevalência deste gene em uma população é de 1/1000 e que a prevalência da doença é de 1%. Sabendo disso, calcule a probabilidade de ter o gene X dado que você tem a doença.

$$P(\text{gene } X) = 1/1000$$

$$P(\text{doença}) = 1/100$$

$$P(\text{doença}|\text{gene } X) = 0,5$$

$$P(\text{gene } X|\text{doença}) = ?$$

$$P(\text{gene } X|\text{doença}) = \frac{P(\text{doença}|\text{gene } X)P(\text{gene } X)}{P(\text{doença})}$$

$$P(\text{gene } X|\text{doença}) = \frac{0,5 \cdot 1/1000}{1/100} = 0,05$$

Estendendo o teorema de Bayes para distribuição

“Não existe uma medida verdadeira, mas sim uma certa distribuição de probabilidade associada às suas crenças subjetivas” → Estatísticos bayesianos enxergam as probabilidades na forma de distribuição.

$$P(H|E) = \frac{P(E|H).P(H)}{P(E)}$$

$$P(H|E) \propto P(E|H).P(H)$$

Probabilidade a posteriori

Verossimilhança

Probabilidade a priori

Distribuição a posteriori

Distribuição dos dados

Distribuição a priori

Transformar as probabilidades em distribuição

Estendendo o teorema de Bayes para distribuição

$$P(H|E) \propto P(E|H) \cdot P(H)$$

Voltando ao exemplo da moeda.

$P(H)$ → Probabilidade a priori → Crença subjetiva da proporção de caras (vamos supor que é de $\frac{1}{4}$);

Distribuição beta → modelar distribuição de probabilidades com dados de proporção;

$$f(x) = \frac{1}{\beta(\alpha, \beta)} x^{\alpha-1} (1-x)^{\beta-1}, 0 < x < 1$$

Achar valores de alfa e beta onde a distribuição fique centrada em 0.25;


Estendendo o teorema de Bayes para distribuição

Determinar alfa e beta onde a distribuição fique centrada em 0.25;

$$\mu = \frac{\alpha}{\alpha + \beta}$$

$$\sigma^2 = \frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}$$

Alfa = 2, Beta = 5



Estendendo o teorema de Bayes para distribuição

$$P(H|E) \propto P(E|H) \cdot P(H)$$

$P(E|H)$ → Probabilidade da evidência dado uma hipótese;

Para obter esta probabilidade precisamos de **evidência** e evidência são os **dados**.

Para obter dados, precisamos realizar **experimento**: Jogadas de 10 moedas:

- cada jogada é um Bernoulli {cara, coroa}.
- Combinação das 10 jogadas → distribuição binomial.

$$P(k) = \binom{n}{k} p^k (1 - p)^{n-k}$$

Estendendo o teorema de Bayes para distribuição

Para obter dados, precisamos realizar **experimento**: Jogadas de 10 moedas:


- cada jogada é um Bernoulli {cara, coroa}.
- Combinação das 10 jogadas → distribuição binomial.

$$P(k) = \binom{n}{k} p^k (1 - p)^{n-k}$$

Suponha que das 10 jogadas, 5 deram cara.

- Frequentista → $P(\text{cara}) = p = \text{proporção de caras} = 0.5$

$$P(k) = \binom{10}{k} 0.5^k (1 - 0.5)^{10-k}$$



Estendendo o teorema de Bayes para distribuição

Suponha que das 10 jogadas, 5 deram cara.

- Bayesiana $\rightarrow P(\text{cara})=p$ é uma variável aleatória \rightarrow infinitos modelos plausíveis, um para cada valor de p .

$$P(5 \text{ caras em } 10|p) = \binom{10}{5} p^5 (1 - p)^5$$

Probabilidade de um resultado dado um $p \rightarrow$ **Verossimilhança(p)**

Estendendo o teorema de Bayes para distribuição

$$P(H|E) \propto P(E|H) \cdot P(H)$$

$$P(H) = \frac{1}{\beta(\alpha, \beta)} x^{\alpha-1} (1-x)^{\beta-1}$$

$$P(H) = \frac{1}{\beta(\alpha, \beta)} p^{\alpha-1} (1-p)^{\beta-1}$$

$$P(E|H) = \binom{n}{k} p^k (1-p)^{n-k}$$

$$P(H|E) \propto \binom{n}{k} p^k (1-p)^{n-k} \cdot \frac{1}{\beta(\alpha, \beta)} p^{\alpha-1} (1-p)^{\beta-1}$$

Estendendo o teorema de Bayes para distribuição

$$P(H|E) \propto P(E|H). P(H)$$

$$P(H|E) \propto \binom{n}{k} p^k (1-p)^{n-k} \cdot \frac{1}{\beta(\alpha, \beta)} p^{\alpha-1} (1-p)^{\beta-1}$$

$$a^m \cdot a^n = a^{m+n}$$

$$P(H|E) \propto \binom{n}{k} \frac{1}{\beta(\alpha, \beta)} p^{k+\alpha-1} (1-p)^{n-k+\beta-1}$$

Considerar constante como c

$$P(H|E) \propto c p^{k+\alpha-1} (1-p)^{n-k+\beta-1}$$

Estendendo o teorema de Bayes para distribuição

$$P(H|E) \propto cp^{k+\alpha-1} (1-p)^{n-k+\beta-1}$$

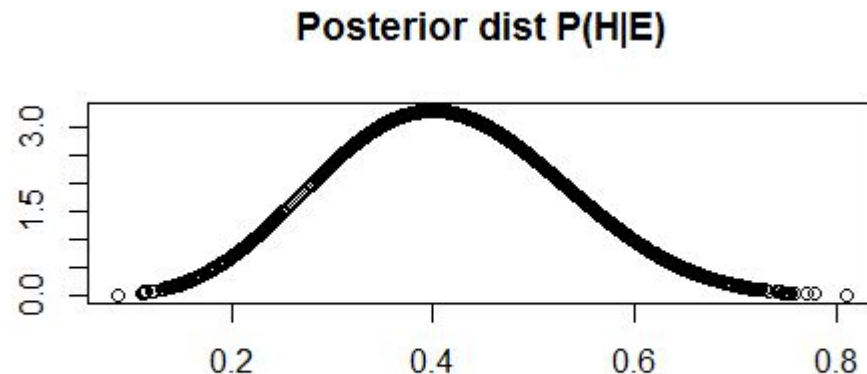
Segue uma distribuição beta:

$$f(x) = \frac{1}{\beta(\alpha,\beta)} x^{\alpha-1} (1-x)^{\beta-1}, 0 < x < 1$$

onde:

- **alfa2** = **k** + **alfa** → 5 + 2 = 7
- **beta2** = **n** - **k** + **beta** → 10 - 5 + 5 = 10

Distribuição posteriori = beta(7, 10)



Estendendo o teorema de Bayes para distribuição

$$P(H|E) \propto cp^{k+\alpha-1} (1-p)^{n-k+\beta-1}$$


Segue uma distribuição beta:

$$f(x) = \frac{1}{\beta(\alpha,\beta)} x^{\alpha-1} (1-x)^{\beta-1}, 0 < x < 1$$

onde:

- **alfa2** = **k** + **alfa** → 5 + 2 = 7
- **beta2** = **n** - **k** + **beta** → 10 - 5 + 5 = 10

Distribuição posteriori = beta(7, 10)



Atualizando o modelo com novos dados

Exercício:

Vamos supor que você tenha feito um novo experimento com 10 jogadas de moedas e chegou nos mesmos resultados. Utilize o modelo posteriori calculado anteriormente como modelo priori e determine um novo modelo posteriori.

Atualizando o modelo com novos dados

Exercício:

Vamos supor que você tenha feito um novo experimento com 10 jogadas de moedas e chegou nos mesmos resultados (5 caras em 10 jogadas). Utilize o modelo posteriori calculado anteriormente como modelo priori e determine um novo modelo posteriori.

$$P(H|E) \propto cp^{k+\alpha-1} (1-p)^{n-k+\beta-1}$$

- **alfa2** = **k** + **alfa** → 5 + 7 = 12
- **beta2** = **n** - **k** + **beta** → 10 - 5 + 10 = 15


Atualizando o modelo com novos dados

Exercício:

Vamos supor que você tenha feito um novo experimento com 10 jogadas de moedas e chegou nos mesmos resultados (5 caras em 10 jogadas). Utilize o modelo posteriori calculado anteriormente como modelo priori e determine um novo modelo posteriori.

$$P(H|E) \propto cp^{k+\alpha-1}$$

- **alfa2** = **k** + **alfa** → 5 + 7 = 12
- **beta2** = **n** - **k** + **beta** → 10 - 5 + 10 = 15



Essência do algoritmo bayesiano

$$P(\textit{Modelo}|\textit{dados}) \propto P(\textit{Dados}|\textit{modelo})P(\textit{Modelo})$$

$$\textit{Posteriori} \propto \textit{Verossimilhança} \cdot \textit{Priori}$$

“Modelo subjetivo a priori é atualizado por um modelo de dados (verossimilhança) para produzir uma distribuição posteriori, combinando a subjetividade do conhecimento do pesquisador com a objetividade dos dados observados.”